

Marvis Osazuwa Lebenslauf

Marvis Osazuwa

Analytics Engineer • Data Scientist

Persönliche Daten

Anschrift	Manchester, Vereinigtes Königreich
E-Mail	marvis.osazuwa@hotmail.com
Telefon	+44 7349 949871
LinkedIn	linkedin.com/in/marvisosazuwa
GitHub	github.com/marz1307
Portfolio	marvisosazuwa.com

Profil

Analytics Engineer und Data Scientist mit Produktionserfahrung in B2B-SaaS-Customer-Analytics. Spezialisiert auf Datensysteme über den gesamten Lebenszyklus: orchestrierte Pipelines, dimensionale Modellierung und angewandtes ML mit Erklärbarkeit, in Python, SQL und dbt. Greenfield-Customer-Intelligence-Datenschicht ausgeliefert und eigenständig einen End-to-End-Churn-Prediction-Stack in Produktion gebracht. MSc Data Science mit Auszeichnung. Volles UK-Arbeitsrecht (Graduate Visa, kein Sponsoring nötig). EU-Blue-Card-berechtigt.

Berufserfahrung

Analytics Engineer • Force24 • Leeds, Vereinigtes Königreich (Hybrid) • Befristeter Vertrag, Januar 2026 bis April 2026

Marketing-Automation-SaaS. Ein 16-Wochen-Teamprojekt: eine dreistufige Customer-Intelligence-Plattform. Innerhalb der gemeinsamen Lieferung verantwortete ich die Datenschicht vollständig als alleiniger Architekt und Autor, war primärer Autor über 8 Backend-Domänen und lieferte das kundenseitige Frontend aus.

- Alleiniger Architekt und Autor einer dbt- und Dagster-Datenpipeline, die 4 voneinander unabhängige Geschäftssysteme zu einem analyseergebnis-bereiten Warehouse auf einem deduplizierten Account-Spine konsolidierte. Etwa 40 dbt-Modelle über Staging-, Intermediate- und Marts-Ebenen, 5 tägliche Dagster-Schedules. Eine kanonische Kunden-ID im gesamten Unternehmen etabliert, wodurch Datensatz-Matching-Lücken beseitigt wurden, die zuvor CSM-Bücher nicht verknüpfbar machten.
- Tägliche Pipeline-Rechenzeit um etwa 95 % reduziert durch Umarchitektur hochvolumiger Revenue-Modelle als inkrementell auf einer Append-Only-Raw-Schicht mit deterministischen Hash-IDs. Plattform auf Oracle Cloud produktiv genommen mit idempotentem Bootstrap, TLS, VPN-Allowlist und dreistufigen Operator-Runbooks, sodass sie rund um die Uhr bei null Infrastrukturkosten läuft.
- Eine Black-Box-Best-Guess-Attribution zwischen Support-Tickets und Accounts durch eine deterministische 10-Schritte-Klassifizierungskette ersetzt, wodurch Support-Kennzahlen gegenüber Auditoren und Customer Success Managern verteidigbar wurden.
- End-to-End-Korrektheit gesichert mit 123 dbt-Tests und 82 pytest-Tests, wobei 22 Datenqualitätsfehler im ersten Produktionsbuild aufgedeckt und behoben wurden. Stille Metrik-Drift wird in CI gefangen, nicht im Vorstandsmeeting.
- Customer-Backend und Angular-UI gebaut: Customer-Liste mit 10 serverseitigen Filtern, Dashboard- und Reporting-Endpoints sowie die Action-Tracker-Seite (alleiniger Autor) mit strukturierter Ergebniserfassung über 7 Ergebnistypen. Die erfassten Ergebnisse bilden den ersten gelabelten Trainingsdatensatz für eine geplante Causal-Model-Schicht.

Stack: Dagster · dbt · PostgreSQL · Python · FastAPI · Redis · Angular · Docker · Caddy · Oracle Cloud · Git

CRM Data Specialist · Natural Clinic · Istanbul, Türkei · 06/2024 – 01/2025

Healthcare-Marketing-Operation. Verantwortung für CRM-Daten und Analytik in den Bereichen Patientenakquise, Conversion und Bindung.

- CRM-Datenebene durchgängig neu aufgebaut und als Single Source of Truth für Vertrieb, Marketing und klinische Operations etabliert. Lead-Reaktionszeit –30 %, Conversion +15 %, Duplikate und Datenfehler –40 %, E-Mail-Engagement +25 %.
- Echtzeit-Dashboards und Executive-Reports in Power BI gestaltet und ausgeliefert, die wöchentliche manuelle Tabellen ersetzen und der Geschäftsleitung erstmals laufende Sichtbarkeit gaben.
- CRM mit dem Marketing-Automation-Stack (E-Mail, SMS, Paid Funnels) integriert sowie Datenflüsse zwischen CRM, Patientenmanagementsystem und Marketing-Tools entwickelt, wodurch drei Tage manueller Abstimmung pro Woche entfielen.
- Tägliche Zusammenarbeit mit Marketing, klinischen Operations und Kundenservice, um unklare Geschäftsfragen in strukturierte Datenmodelle und messbare Ergebnisse zu übersetzen.

Stack: SQL · Python · Power BI · Zoho CRM · Marketing-Automation · Workflow-Automation

Strategic Data Insights Analyst · Federal Mortgage Bank of Nigeria · Abuja, Nigeria · 12/2018 – 11/2019

Bundesweite Hypothekeninstitution für den nigerianischen Wohnungsbaufonds. Kreditportfolio-Analytik und IT-Governance-Reporting in der Asset Creation Unit der Loan-Administration-Gruppe, unter Senior-Supervision.

- Zu einer Datenintegritätsoffensive beigetragen, die die Genauigkeit der Kerndatensätze in sechs Monaten um 40 % steigerte und das Risiko fehlerhafter Kreditgenehmigungen wesentlich reduzierte.
- Python- und SQL-Analytik auf Basis von Tableau gebaut, um Rückzahlungsverhalten zu verfolgen, und damit eine 15-prozentige Effizienzsteigerung im Rückzahlungs-Monitoring sowie eine 25-prozentige Reduktion des manuellen Dateneingabe-Aufwands unterstützt.
- Die Verschlinkung von IT-Asset-Governance und Genehmigungsworkflows unterstützt, mit einer 30-prozentigen Reduktion der Bearbeitungszeit als Ergebnis.

Stack: Python · SQL · Tableau · Excel

Ausbildung

MSc Data Science · University of Salford, Manchester, Vereinigtes Königreich · 01/2025 – 05/2026 · Note: Distinction (mit Auszeichnung) Schwerpunkte: Machine Learning, Big-Data-Engineering, angewandte Statistik, datengetriebene Entscheidungsfindung.

MSc Big Data Analytics and Management · Bahçeşehir Üniversitesi, Istanbul, Türkei · 09/2020 – 03/2023 · Note: 3,67/4,00 Masterarbeit: PySpark-Pipeline zum Ranking und zur Empfehlung von Spielern aus fünf europäischen Fußballligen anhand von UEFA-Event-Daten.

BEng Computer Engineering · University of Benin, Edo, Nigeria · 09/2011 – 08/2017

Projekte

Agentic ELT Data Platform for Customer Intelligence · MSc-Dissertation (Salford) · 2026 · Live-B2B-SaaS-Umgebung

Eigenständiges Solo-Projekt von Anfang bis Ende: Ich habe jede Schicht selbst entworfen und geschrieben, von der Ingestion bis zur Serving-API, gegen eine Live-B2B-SaaS-Umgebung unter NDA. Es lief auf derselben Umgebung wie mein Force24-Vertrag, ist aber unabhängige Eigenarbeit; die Force24-Plattform selbst war eine Teamlieferung. Eigenentwickelte Python-Ingestion mit über 1 Mio. Datensätzen aus mehreren Vendor-APIs in ein JSONB-first PostgreSQL-Warehouse via Dagster ingestiert, durch 48 dbt-Modelle modelliert und mit einem Drei-Modell-Intelligence-Stack versehen: Survival-Analyse (wann Accounts abwandern), Gradient-Boosted-Klassifikation mit SHAP-Erklärungen (wie wahrscheinlich Churn ist und welche Treiber wirken) sowie Causal Inference, die reaktive Zuweisungs-Selektionsbias bei der Bewertung der CSM-Wirksamkeit korrigiert. Bereitgestellt über einen FastAPI-Service mit JWT-Auth und Row-Level-Security, ein Angular-Dashboard und einen Model-Context-Protocol-(MCP)-Endpoint, der die gesamte Intelligence-Schicht für agentische LLM-Workflows zugänglich macht. Hochrisiko-Accounts für priorisierte CSM-Retention-Aktionen identifiziert. Python PostgreSQL JSONB dbt Dagster PostgresML XGBoost SHAP Causal Inference Survival Analysis FastAPI Angular MCP

Pharmaceutical Side Effect Classification · 2025 · Healthcare-ML

Produktionsreifer Multi-Class-Klassifikator zur Zuordnung von Freitext-Beschreibungen unerwünschter Arzneimittelereignisse zu zehn klinischen Kategorien über 11.825 zugelassene Medikamente. Random Forest mit 98,5 % Genauigkeit auf der Test-Holdout-Menge, Logistic Regression als interpretierbarer Vergleich bei 97,2 %. Inference-CLI und pytest-Testsuite enthalten. Python scikit-learn TF-IDF Random Forest Logistic Regression

Big Data Player Scouting · MSc-Thesis · 2023 · Sport / Big Data

Verteilte PySpark-Pipeline zur Bewertung und Empfehlung von über 500 Spielern aus La Liga, Serie A, Premier League, Bundesliga und Ligue 1 anhand von UEFA-Event-Daten und der PlayeRank-Methodik. Veröffentlichte Thesis, öffentlicher Quellcode. Python PySpark Big Data Recommender Systems

Equity Forecasting · 2025 · Finanzielle Zeitreihen

End-to-End-R-Analysepaket für univariate Aktienprognosen auf 5.124 NYSE-Tagesbeobachtungen. ARIMA, saisonales ARIMA und ETS über ein MODEL_REGISTRY-Pattern. Formale Residualdiagnostik (Ljung-Box, Shapiro-Wilk) und Stationaritätstests (ADF, KPSS) zu einer einheitlichen Entscheidungsregel kombiniert. R ARIMA ETS Zeitreihen Statistische Tests

Technische Kenntnisse

Sprachen: SQL · Python (pandas, NumPy, scikit-learn) · R · PySpark · Bash **Warehouse & Pipelines:** PostgreSQL (JSONB + GIN) · SQL Server / T-SQL · dbt · Dagster · Kimball-Dimensionsmodellierung · ELT/ETL-Design **Distributed & Lakehouse:** PySpark · Spark MLlib · MLflow · Databricks **ML & Statistik:** XGBoost · SHAP · scikit-survival · econml (DR-Learner) · PostgresML · Causal Inference · Survival Analysis · RoBERTa- und Transformer-Sentimentanalyse (NLP) · TF-IDF · LDA · ARIMA/ETS-Zeitreihen **Serving & agentischer Zugriff:** FastAPI · REST APIs · Model-Context-Protocol-(MCP)-Endpoints für LLM-Agenten · Docker · Caddy · Oracle Cloud **BI:** Power BI · Tableau **CI & Versionskontrolle:** Git · GitHub Actions · pytest **Grundkenntnisse (Kurse und Zertifikate):** Snowflake · BigQuery (Google-Cloud-zertifiziert) · Airflow · Looker · AWS · GCP · Azure

Sprachen

Englisch: Muttersprachlich · **Deutsch:** B1

Zertifikate

Engineer Data for Predictive Modeling with BigQuery ML (Google Cloud) · Python for Data Science, AI & Development (Coursera) · Generative AI for Business Leaders (Coursera) · Enterprise Design Thinking Practitioner (IBM) · Tableau for Data Scientists (LinkedIn Learning) · Statistics Foundations 1–4 (LinkedIn Learning)