

Marvis Osazuwa

Analytics Engineer · Data Scientist

Manchester, Vereinigtes Königreich · +44 7349 949871 · marvis.osazuwa@hotmail.com · linkedin.com/in/marvisosazuwa · github.com/marz1307 · marvisosazuwa.com

PROFIL

Analytics Engineer und Data Scientist mit Produktionserfahrung in B2B-SaaS-Customer-Analytics. Spezialisiert auf Datensysteme über den gesamten Lebenszyklus: orchestrierte Pipelines, dimensionale Modellierung und angewandtes ML mit Erklärbarkeit, in Python, SQL und dbt. Greenfield-Customer-Intelligence-Datenschicht ausgeliefert und eigenständig einen End-to-End-Churn-Prediction-Stack in Produktion gebracht. MSc Data Science mit Auszeichnung. Volles UK-Arbeitsrecht (Graduate Visa, kein Sponsoring nötig). EU-Blue-Card-berechtigt.

BERUFSERFAHRUNG

Analytics Engineer · Force24 · Leeds, Vereinigtes Königreich (Hybrid)

Befristeter Vertrag, Januar 2026 bis April 2026

Marketing-Automation-SaaS. Ein 16-Wochen-Teamprojekt: eine dreistufige Customer-Intelligence-Plattform. Innerhalb der gemeinsamen Lieferung verantwortete ich die Datenschicht vollständig als alleiniger Architekt und Autor, war primärer Autor über 8 Backend-Domänen und lieferte das kundenseitige Frontend aus.

- Alleiniger Architekt und Autor einer dbt- und Dagster-Datenpipeline, die 4 voneinander unabhängige Geschäftssysteme zu einem analyseergebnis-bereiten Warehouse auf einem deduplizierten Account-Spine konsolidierte. Etwa 40 dbt-Modelle über Staging-, Intermediate- und Marts-Ebenen, 5 tägliche Dagster-Schedules. Eine kanonische Kunden-ID im gesamten Unternehmen etabliert, wodurch Datensatz-Matching-Lücken beseitigt wurden, die zuvor CSM-Bücher nicht verknüpfbar machten.
- Tägliche Pipeline-Rechenzeit um etwa 95 % reduziert durch Umarchitektur hochvolumiger Revenue-Modelle als inkrementell auf einer Append-Only-Raw-Schicht mit deterministischen Hash-IDs. Plattform auf Oracle Cloud produktiv genommen mit idempotentem Bootstrap, TLS, VPN-Allowlist und dreistufigen Operator-Runbooks, sodass sie rund um die Uhr bei null Infrastrukturkosten läuft.
- Eine Black-Box-Best-Guess-Attribution zwischen Support-Tickets und Accounts durch eine deterministische 10-Schritte-Klassifizierungskette ersetzt, wodurch Support-Kennzahlen gegenüber Auditoren und Customer Success Managern verteidigbar wurden.
- End-to-End-Korrektheit gesichert mit 123 dbt-Tests und 82 pytest-Tests, wobei 22 Datenqualitätsfehler im ersten Produktionsbuild aufgedeckt und behoben wurden. Stille Metrik-Drift wird in CI gefangen, nicht im Vorstandsmeeting.
- Customer-Backend und Angular-UI gebaut: Customer-Liste mit 10 serverseitigen Filtern, Dashboard- und Reporting-Endpoints sowie die Action-Tracker-Seite (alleiniger Autor) mit strukturierter Ergebniserfassung über 7 Ergebnistypen. Die erfassten Ergebnisse bilden den ersten gelabelten Trainingsdatensatz für eine geplante Causal-Model-Schicht.

Stack: Dagster, dbt, PostgreSQL, Python, FastAPI, Redis, Angular, Docker, Caddy, Oracle Cloud, Git.

CRM Data Specialist · Natural Clinic · Istanbul, Türkei

Juni 2024 – Januar 2025

Healthcare-Marketing-Operation. Verantwortung für CRM-Daten und Analytik in den Bereichen Patientenakquise, Conversion und Bindung.

- CRM-Datenebene durchgängig neu aufgebaut und als Single Source of Truth für Vertrieb, Marketing und klinische Operations etabliert. Lead-Reaktionszeit -30 %, Conversion +15 %, Duplikate und Datenfehler -40 %, E-Mail-Engagement +25 %.
- Echtzeit-Dashboards und Executive-Reports in Power BI gestaltet und ausgeliefert, die wöchentliche manuelle Tabellen ersetzen und der Geschäftsleitung erstmals laufende Sichtbarkeit gaben.
- CRM mit dem Marketing-Automation-Stack (E-Mail, SMS, Paid Funnels) integriert sowie Datenflüsse zwischen CRM, Patientenmanagementsystem und Marketing-Tools entwickelt, wodurch drei Tage manueller Abstimmung pro Woche entfielen.
- Tägliche Zusammenarbeit mit Marketing, klinischen Operations und Kundenservice, um unklare Geschäftsfragen in strukturierte Datenmodelle und messbare Ergebnisse zu übersetzen.

Stack: SQL, Python, Power BI, Zoho CRM, Marketing-Automation, Workflow-Automation.

Strategic Data Insights Analyst · Federal Mortgage Bank of Nigeria · Abuja, Nigeria

Dezember 2018 – November 2019

Bundesweite Hypothekeninstitution für den nigerianischen Wohnungsbaufonds. Kreditportfolio-Analytik und IT-Governance-Reporting in der Asset Creation Unit der Loan-Administration-Gruppe, unter Senior-Supervision.

- Zu einer Datenintegritätsoffensive beigetragen, die die Genauigkeit der Kerndatensätze in sechs Monaten um 40 % steigerte und das Risiko fehlerhafter Kreditgenehmigungen wesentlich reduzierte.
- Python- und SQL-Analytik auf Basis von Tableau gebaut, um Rückzahlungsverhalten zu verfolgen, und damit eine 15-prozentige Effizienzsteigerung im Rückzahlungs-Monitoring sowie eine 25-prozentige Reduktion des manuellen Dateneingabe-Aufwands unterstützt.
- Die Verschlinkung von IT-Asset-Governance und Genehmigungsworkflows unterstützt, mit einer 30-prozentigen Reduktion der Bearbeitungszeit als Ergebnis.

Stack: Python, SQL, Tableau, Excel.

AUSBILDUNG

MSc Data Science · University of Salford · Manchester, Vereinigtes Königreich

Januar 2025 – Mai 2026 · Note: Distinction (mit Auszeichnung) · Dissertation: Agentic ELT Data Platform for Customer Intelligence

MSc Big Data Analytics and Management · Bahçeşehir Üniversitesi · Istanbul, Türkei

September 2020 – März 2023 · Note: 3,67/4,00 · Masterarbeit: PySpark-Pipeline zum Ranking und zur Empfehlung von Spielern

BEng Computer Engineering · University of Benin · Edo, Nigeria

September 2011 – August 2017

PROJEKTE

Agentic ELT Data Platform for Customer Intelligence

MSc-Dissertation (Salford) · 2026 · Live-B2B-SaaS-Umgebung

Eigenständiges Solo-Projekt von Anfang bis Ende: Ich habe jede Schicht selbst entworfen und geschrieben, von der Ingestion bis zur Serving-API, gegen eine Live-B2B-SaaS-Umgebung unter NDA. Es lief auf derselben Umgebung wie mein Force24-Vertrag, ist aber unabhängige Eigenarbeit; die Force24-Plattform selbst war eine Teamlieferung. Eigenentwickelte Python-Ingestion mit über 1 Mio. Datensätzen aus mehreren Vendor-APIs in ein JSONB-first PostgreSQL-Warehouse via Dagster ingestiert, durch 48 dbt-Modelle modelliert und mit einem Drei-Modell-Intelligence-Stack versehen: Survival-Analyse (wann Accounts abwandern), Gradient-Boosted-Klassifikation mit SHAP-Erklärungen (wie wahrscheinlich Churn ist und welche Treiber wirken) sowie Causal Inference, die reaktive Zuweisungs-Selektionsbias bei der Bewertung der CSM-Wirksamkeit korrigiert. Bereitgestellt über einen FastAPI-Service mit JWT-Auth und Row-Level-Security, ein Angular-Dashboard und einen Model-Context-Protocol-(MCP)-Endpoint, der die gesamte Intelligence-Schicht für agentische LLM-Workflows zugänglich macht. Hochrisiko-Accounts für priorisierte CSM-Retention-Aktionen identifiziert.

Python PostgreSQL JSONB dbt Dagster PostgresML XGBoost SHAP Causal Inference Survival Analysis FastAPI Angular MCP

Pharmaceutical Side Effect Classification

Nebenprojekt · 2025 · Healthcare-ML

Produktionsreifer Multi-Class-Klassifikator zur Zuordnung von Freitext-Beschreibungen unerwünschter Arzneimittelereignisse zu zehn klinischen Kategorien über 11.825 zugelassene Medikamente. Random Forest mit 98,5 % Genauigkeit auf der Test-Holdout-Menge, Logistic Regression als interpretierbarer Vergleich bei 97,2 %. Inference-CLI und pytest-Testsuite enthalten.

Python scikit-learn TF-IDF Random Forest Logistic Regression

Big Data Player Scouting (MSc Thesis)

Bahcesehir-Masterarbeit · 2023 · Sport / Big Data

Verteilte PySpark-Pipeline zur Bewertung und Empfehlung von über 500 Spielern aus La Liga, Serie A, Premier League, Bundesliga und Ligue 1 anhand von UEFA-Event-Daten und der PlayeRank-Methodik. Veröffentlichte Thesis, öffentlicher Quellcode.

Python PySpark Big Data Recommender Systems

Equity Forecasting

Nebenprojekt · 2025 · Finanzielle Zeitreihen

End-to-End-R-Analysepaket für univariate Aktienprognosen auf 5.124 NYSE-Tagesbeobachtungen. ARIMA, saisonales ARIMA und ETS über ein MODEL_REGISTRY-Pattern. Formale Residualdiagnostik (Ljung-Box, Shapiro-Wilk) und Stationaritätstests (ADF, KPSS) zu einer einheitlichen Entscheidungsregel kombiniert.

R ARIMA ETS Zeitreihen Statistische Tests

TECHNISCHE KENNTNISSE

Sprachen: SQL, Python, R, PySpark, T-SQL, Bash

Transformation & Orchestrierung: dbt, Dagster, Apache Spark, Airflow

Warehouse & Speicher: PostgreSQL (JSONB + GIN), Snowflake, BigQuery, Databricks, SQL Server

Service-Schicht: FastAPI, REST APIs, Docker, Caddy, Model Context Protocol (MCP)

Versionskontrolle & CI: Git, GitHub, GitHub Actions, pytest

Cloud: AWS, GCP, Azure, Oracle Cloud

ML & Statistik: scikit-learn, XGBoost, PostgresML, scikit-survival, econml (DR-Learner), SHAP, MLflow, RoBERTa, ARIMA, Zeitreihenanalyse, NLP, Sentimentanalyse, TF-IDF, LDA, Causal Inference, Survival Analysis, A/B-Testing / Experimentation

Agentische KI: Model Context Protocol (MCP), agentisches ELT, LLM-zugängliche Datenschichten

BI & Visualisierung: Power BI, Tableau, Looker

SPRACHEN

- **Englisch:** Muttersprachlich
- **Deutsch:** B1

ZERTIFIKATE

- Engineer Data for Predictive Modeling with BigQuery ML · Google Cloud
- Python for Data Science, AI & Development · Coursera
- Generative AI for Business Leaders · Coursera
- Enterprise Design Thinking Practitioner / Team Essentials for AI / Co-Creator · IBM

EHRENAMT & ENGAGEMENT

Microsoft Learn Student Ambassador · Bahçeşehir Üniversitesi · Istanbul, Türkei

September 2020 – Juni 2023 (2 Jahre 9 Monate) · Universitätsübergreifende Azure-Workshops, Community-Hackathon, Aufbau des Microsoft-Learn-Chapters an der Bahçeşehir.

Ab sofort verfügbar (MSc abgeschlossen Mai 2026). Zielrollen: Analytics Engineer / Data Scientist im Vereinigten Königreich und in Deutschland/EU. UK Graduate Visa: kein Sponsoring nötig; EU-Blue-Card-berechtigt.