

Marvis Osazuwa

Analytics Engineer · Data Scientist



PERSÖNLICHE DATEN

Anschrift Manchester, Vereinigtes Königreich
Telefon +44 7349 949871
E-Mail marvis.osazuwa@hotmail.com
LinkedIn linkedin.com/in/marvisosazuwa
GitHub github.com/marz1307
Portfolio marvisosazuwa.com

PROFIL

Analytics Engineer und Data Scientist, der produktionsreife Datenebenen durchgängig baut — dbt-Transformationen unter CI, Dagster-Orchestrierung, Kimball-modelliertes Warehousing — mit eingebettetem ML, wo es trägt: Survival Analysis (C-Index ~0,94), Gradient-Boosted-Klassifikation mit SHAP (AUC ~0,95), DR-Learner-Causal-Inference. Alleiniger Architekt der Customer-Intelligence-Datenebene bei Force24 (über 40 dbt-Modelle, tägliche Rechenzeit ca. 95% reduziert). Der rote Faden: Ich mache Daten erst vertrauenswürdig, dann prädictiv — jede Schicht durch Tests in der CI gesichert, jedes Modell mit Erklärung ausgeliefert, das Warehouse selbst über einen Model-Context-Protocol-(MCP)-Endpoint direkt für LLM-Agenten abfragbar. Aktuell baue ich unabhängige Enterprise-Datenprojekte auf demselben Stack. Deutsch auf B1-Niveau, in aktiver Vertiefung. EU-Blue-Card-berechtigt für Deutschland: Datenrollen zählen zu den Engpassberufen, reguläres Verfahren ohne Sponsoring-Lizenz des Arbeitgebers. Umzug nach Deutschland geplant.

BERUFSERFAHRUNG

Analytics Engineer · Force24 · Leeds, Vereinigtes Königreich (Hybrid)

Befristeter Vertrag · 01/2026 – 04/2026

Marketing-Automation-SaaS. Ein 16-Wochen-Teamprojekt: eine dreistufige Customer-Intelligence-Plattform. Innerhalb der gemeinsamen Lieferung verantwortete ich die Datenebene vollständig als alleiniger Architekt und Autor, war primärer Autor über 8 Backend-Domänen und lieferte das kundenseitige Frontend aus.

- Alleiniger Architekt und Autor einer dbt- und Dagster-Datenpipeline, die 4 voneinander unabhängige Geschäftssysteme zu einem analysefähigen Warehouse auf einem deduplizierten Account-Spine konsolidierte (über 40 dbt-Modelle über Staging-, Intermediate- und Marts-Ebenen, 5 tägliche Dagster-Schedules, ca. 93 % alleiniger Commit-Anteil). Eine kanonische Kunden-ID im gesamten Unternehmen etabliert, die die Datensatz-Matching-Lücken schloss, die CSM-Bücher zuvor nicht verknüpfbar machten.
- Tägliche Pipeline-Rechenzeit um ca. 95 % reduziert durch Umarchitektur hochvolumiger Revenue-Modelle als inkrementell auf einer Append-Only-Raw-Schicht mit deterministischen Hash-IDs. Plattform auf Oracle Cloud Infrastructure produktiv genommen mit idempotentem Bootstrap, TLS, VPN-Allowlist und dreistufigen Operator-Runbooks, sodass sie rund um die Uhr bei null Infrastrukturkosten läuft.
- Support-Attributionsgenauigkeit auf auditorensicher gehoben, indem eine deterministische 10-Schritte-Klassifizierungskette jeden Datensatz einem Account eindeutig zuordnet und damit eine Black-Box-Best-Guess-Logik ersetzt. Letzte offene Finding im Customer-Success-Metrikreview geschlossen.
- End-to-End-Korrektheit gesichert mit 123 dbt-Tests und 82 pytest-Tests, abgesichert über die GitHub-Actions-CI, wobei 22 Datenqualitätsfehler im ersten Produktionsbuild aufgedeckt und behoben wurden. Stille Metrik-Drift schlägt jetzt als fehlgeschlagener Test auf, nicht im Vorstandsmeeting.
- Customer-Facing-Backend und Angular-UI ausgeliefert (Customer-Liste mit 10 serverseitigen Filtern, Dashboard- und Reporting-Endpoints, alleinig verantwortete Action-Tracker-Seite über 7 Ergebnistypen), damit Customer Success einen einheitlichen Workflow für Retention-Aktionen und den ersten gelabelten Outcome-Datensatz für eine geplante kausale Uplift-Schicht bekommt.

Stack: Dagster, dbt, PostgreSQL, Python, FastAPI, Redis, Angular, Docker, Caddy, Oracle Cloud, GitHub Actions, Git.

CRM Data Specialist · Natural Clinic · Istanbul, Türkei

06/2024 – 01/2025

Marketingbetrieb im Healthcare-Sektor. Verantwortung für CRM-Daten und Analytik in den Bereichen Patientenakquise, Conversion und Bindung.

- CRM-Datenebene durchgängig neu aufgebaut und als Single Source of Truth für Vertrieb, Marketing und klinische Operations etabliert. Lead-Reaktionszeit -30 %, Conversion +15 %, Duplikate und Datenfehler -40 %, E-Mail-Engagement +25 %.
- Wöchentliches manuelles Tabellen-Reporting durch Echtzeit-Power-BI-Dashboards und Executive-Reports ersetzt; Reporting-Latenz von 7 Tagen auf live reduziert, ca. 6 Analystenstunden pro Woche bei der Berichtserstellung freigesetzt.
- CRM mit dem Marketing-Automation-Stack (E-Mail, SMS, Paid Funnels) integriert sowie Datenflüsse zwischen CRM, Patientenmanagementsystem und Marketing-Tools entwickelt, wodurch drei Tage manueller Abstimmung pro Woche entfielen.
- Unklare Stakeholder-Anfragen aus Marketing, klinischen Operations und Kundenservice in 12+ ausgelieferte Datenmodelle und Dashboards übersetzt, darunter die Lead-Scoring- und Conversion-Funnel-Modelle, die den 15 % Conversion-Uplift trieben.

Stack: SQL, Python, Power BI, Zoho CRM, Marketing-Automation, Workflow-Automation.

Strategic Data Insights Analyst · Federal Mortgage Bank of Nigeria · Abuja, Nigeria

12/2018 – 11/2019

Bundesweite Hypothekeninstitution für den nigerianischen Wohnungsbaufonds. Kreditportfolio-Analytik und IT-Governance-Reporting in der Asset Creation Unit der Loan-Administration-Gruppe.

- Zu einer Datenintegritätsoffensive beigetragen, die die Genauigkeit der Kerndatensätze in sechs Monaten um 40 % steigerte und das Risiko fehlerhafter Kreditgenehmigungen wesentlich reduzierte.
- Python- und SQL-Analytik auf Basis von Tableau gebaut, um Rückzahlungsverhalten zu verfolgen, und damit eine 15-prozentige Effizienzsteigerung im Rückzahlungs-Monitoring sowie eine 25-prozentige Reduktion des manuellen Dateneingabe-Aufwands unterstützt.
- Bearbeitungszeit der IT-Asset-Governance-Genehmigungen um 30 % reduziert durch Neukartierung des Approval-Workflows und Instrumentierung des Stage-Level-Reportings in Tableau, wodurch die Median-Zeit-bis-Genehmigung in der Loan-Administration-Gruppe geschrumpft ist.

Stack: Python, SQL, Tableau, Excel.

AUSBILDUNG

MSc Data Science · University of Salford · Manchester, Vereinigtes Königreich

01/2025 – 05/2026 · Note: Distinction (mit Auszeichnung) · Dissertation: Agentic ELT Data Platform for Customer Intelligence · Schwerpunkte: ML, Big-Data-Engineering, angewandte Statistik

MSc Big Data Analytics and Management · Bahçeşehir Üniversitesi · Istanbul, Türkei

09/2020 – 03/2023 · Note: 3,67 / 4,00 (ca. 1,7 nach deutschem System) · Masterarbeit: PySpark-Pipeline für Spielerempfehlungen in fünf europäischen Fußballligen (UEFA-Event-Daten)

BEng Computer Engineering · University of Benin · Edo, Nigeria

09/2011 – 08/2017

PROJEKTE

Agentic ELT Data Platform for Customer Intelligence

MSc-Dissertation (Salford) · 2026 · Live-B2B-SaaS-Umgebung

Eigenständiges Solo-Projekt von Anfang bis Ende: jede Schicht selbst entworfen und geschrieben, von der Ingestion bis zur Serving-API, gegen eine Live-B2B-SaaS-Umgebung unter NDA. Lief auf derselben Umgebung wie der Force24-Vertrag, ist aber unabhängige Eigenarbeit; die Force24-Plattform selbst war eine Teamlieferung.

- **Ingestion und Warehouse:** Eigene Python-Extraktoren ingestierten über 1 Mio. Datensätze aus mehreren Vendor-APIs in ein JSONB-orientiertes PostgreSQL-Warehouse, orchestriert mit Dagster.
- **Serving und Agent-Zugriff:** FastAPI-Service mit JWT-Auth und Row-Level-Security, Angular-Dashboard sowie Model-Context-Protocol-(MCP)-Endpoint, abfragbar durch jeden MCP-kompatiblen LLM-Agent für Per-Account-Risiko-Profiling, Treibererklärungen und Interventionsempfehlungen. Die Priorisierung der Ausgaben hob Hochrisiko-Accounts für CSM-Retention-Aktionen hervor.
- **Modellierung:** 48 dbt-Modelle über Raw-, Staging-, Intermediate- und Marts-Schichten; mehrschichtiges dimensionales Design nach Kimball.
- **Intelligence-Stack:** Survival-Analyse (kreuzvalidierter C-Index ca. 0,94 auf Held-Out-Kohorte) für Time-to-Churn; Gradient-Boosted-Klassifikation mit SHAP-Erklärungen (AUC ca. 0,95 gegenüber ca. 0,89 Logistic-Baseline) für Churn-Wahrscheinlichkeit und Treiber; DR-Learner-Causal-Inference (econml), die reaktive Zuweisungs-Selektionsbias um ca. 50 Prozentpunkte auf dem naiven Schätzer korrigiert, für eine ehrliche CSM-Treatment-Effect-Schätzung.

Python PostgreSQL JSONB dbt Dagster PostgresML XGBoost SHAP Causal Inference Survival Analysis FastAPI Angular MCP

Pharmaceutical Side Effect Classification

Eigenprojekt · 2025 · Healthcare-ML

Produktionsreifer Multi-Class-Klassifikator zur Zuordnung von Freitext-Beschreibungen unerwünschter Arzneimittelereignisse zu zehn klinischen Kategorien über 11.825 zugelassene Medikamente. Random Forest mit 98,5 % Genauigkeit auf der Test-Holdout-Menge, Logistic Regression als interpretierbarer Vergleich bei 97,2 %. Inference-CLI und pytest-Testsuite enthalten.

Python scikit-learn TF-IDF Random Forest Logistic Regression

Big Data Player Scouting

Masterarbeit · 2023 · Sport / Big Data

Verteilte PySpark-Pipeline zur Bewertung und Empfehlung von über 500 Spielern aus La Liga, Serie A, Premier League, Bundesliga und Ligue 1 anhand von UEFA-Event-Daten und der PlayerRank-Methodik. Veröffentlichte Thesis, öffentlicher Quellcode.

Python PySpark Big Data Recommender Systems

Equity Forecasting

Eigenprojekt · 2025 · Finanzielle Zeitreihen

End-to-End-R-Analysepaket für univariate Aktienprognosen auf 5.124 NYSE-Tagesbeobachtungen. ARIMA, saisonales ARIMA und ETS über ein MODEL_REGISTRY-Pattern. Formale Residualdiagnostik (Ljung-Box, Shapiro-Wilk) und Stationaritätstests (ADF, KPSS) zu einer einheitlichen Entscheidungsregel kombiniert.

R ARIMA ETS Zeitreihen Statistische Tests

TECHNISCHE KENNTNISSE

Sprachen: SQL, Python (pandas, NumPy, scikit-learn), R, PySpark, T-SQL, Bash

Warehousing: PostgreSQL (JSONB + GIN), Snowflake, BigQuery, Databricks, SQL Server

Transformation & Orchestrierung: dbt, Dagster, Apache Spark, Airflow

Service Layer: FastAPI, REST APIs, Docker, Caddy, Model Context Protocol (MCP)

ML & Statistik: scikit-learn, XGBoost, PostgresML, scikit-survival, econml (DR-Learner), SHAP, MLflow, RoBERTa, ARIMA, NLP, Sentimentanalyse, TF-IDF, LDA, Causal Inference, Survival Analysis, A/B-Testing / Experimentation

Agentic AI: Model Context Protocol (MCP), agentische ELT, LLM-zugängliche Datenebenen

BI & Visualisierung: Power BI, Tableau, Looker

Cloud: AWS, GCP, Azure, Oracle Cloud

Versionskontrolle & CI: Git, GitHub, GitHub Actions, pytest

SPRACHEN

• **Englisch:** Muttersprachlich

• **Deutsch:** B1

ZERTIFIKATE

• Engineer Data for Predictive Modeling with BigQuery ML · Google Cloud

• Python for Data Science, AI & Development · Coursera

• Generative AI for Business Leaders · Coursera

• Enterprise Design Thinking Practitioner / Team Essentials for AI / Co-Creator · IBM

ENGAGEMENT

Microsoft Learn Student Ambassador · Bahçeşehir Üniversitesi · Istanbul, Türkei

01/2021 – 09/2023 · Universitätsübergreifende Azure-Workshops und Community-Hackathon mit Ambassadors und Lernenden.

Verfügbarkeit: verfügbar ab Zusage zuzüglich Blue-Card-Verfahren (in der Regel 4–8 Wochen); Umzug nach Deutschland geplant.