

Marvis Osazuwa

Machine Learning Engineer · Data Scientist



PERSÖNLICHE DATEN

Anschrift Manchester, Vereinigtes Königreich
Telefon +44 7349 949871
E-Mail marvis.osazuwa@hotmail.com
LinkedIn linkedin.com/in/marvisosazuwa
GitHub github.com/marz1307
Portfolio marvisosazuwa.com

PROFIL

Machine Learning Engineer und Data Scientist mit Fokus auf Model Serving und Erklärbarkeit: XGBoost (AUC ~0,95) und Survival-Modelle (C-Index ~0,94), ausgeliefert über FastAPI mit JWT und Row-Level-Security, SHAP-Treiber-Erklärungen, In-Database-ML über PostgresML — auf einer bei Force24 durchgängig gebauten produktionsreifen Datenebene. Der rote Faden: Ich mache Daten erst vertrauenswürdig, dann prädiktiv — Modelle hinter authentifizierten APIs mit angehängten SHAP-Erklärungen, nutzbar für Menschen wie LLM-Agenten über einen Model-Context-Protocol-(MCP)-Endpoint. Aktuell baue ich unabhängige Enterprise-Datenprojekte auf demselben Stack. Deutsch auf B1-Niveau, in aktiver Vertiefung. EU-Blue-Card-berechtigt für Deutschland: Datenrollen zählen zu den Engpassberufen, reguläres Verfahren ohne Sponsoring-Lizenz des Arbeitgebers. Umzug nach Deutschland geplant.

BERUFSERFAHRUNG

Analytics Engineer · Force24 · Leeds, Vereinigtes Königreich (Hybrid)

Befristeter Vertrag · 01/2026 – 04/2026

Marketing-Automation-SaaS. Ein 16-Wochen-Teamprojekt: eine dreistufige Customer-Intelligence-Plattform. Innerhalb der gemeinsamen Lieferung verantwortete ich die Datenebene vollständig als alleiniger Architekt und Autor, war primärer Autor über 8 Backend-Domänen und lieferte das kundenseitige Frontend aus.

- Alleiniger Architekt und Autor einer dbt- und Dagster-Datenpipeline, die 4 voneinander unabhängige Geschäftssysteme zu einem analysfähigen Warehouse auf einem deduplizierten Account-Spine konsolidierte (über 40 dbt-Modelle über Staging-, Intermediate- und Marts-Ebenen, 5 tägliche Dagster-Schedules, ca. 93 % alleiniger Commit-Anteil). Eine kanonische Kunden-ID im gesamten Unternehmen etabliert, die die Datensatz-Matching-Lücken schloss, die CSM-Bücher zuvor nicht verknüpfbar machten.
- Tägliche Pipeline-Rechenzeit um ca. 95 % reduziert durch Umarchitektur hochvolumiger Revenue-Modelle als inkrementell auf einer Append-Only-Raw-Schicht mit deterministischen Hash-IDs. Plattform auf Oracle Cloud Infrastructure produktiv genommen mit idempotentem Bootstrap, TLS, VPN-Allowlist und dreistufigen Operator-Runbooks, sodass sie rund um die Uhr bei null Infrastrukturkosten läuft.
- Support-Attributionsgenauigkeit auf auditorensicher gehoben, indem eine deterministische 10-Schritte-Klassifizierungskette jeden Datensatz einem Account eindeutig zuordnet und damit eine Black-Box-Best-Guess-Logik ersetzt. Letzte offene Finding im Customer-Success-Metrikreview geschlossen.
- End-to-End-Korrektheit gesichert mit 123 dbt-Tests und 82 pytest-Tests, abgesichert über die GitHub-Actions-CI, wobei 22 Datenqualitätsfehler im ersten Produktionsbuild aufgedeckt und behoben wurden. Stille Metrik-Drift schlägt jetzt als fehlgeschlagener Test auf, nicht im Vorstandsmeeting.
- Customer-Facing-Backend und Angular-UI ausgeliefert (Customer-Liste mit 10 serverseitigen Filtern, Dashboard- und Reporting-Endpoints, alleinig verantwortete Action-Tracker-Seite über 7 Ergebnistypen), damit Customer Success einen einheitlichen Workflow für Retention-Aktionen und den ersten gelabelten Outcome-Datensatz für eine geplante kausale Uplift-Schicht bekommt.

Stack: Dagster, dbt, PostgreSQL, Python, FastAPI, Redis, Angular, Docker, Caddy, Oracle Cloud, GitHub Actions, Git.

CRM Data Specialist · Natural Clinic · Istanbul, Türkei

06/2024 – 01/2025

Marketingbetrieb im Healthcare-Sektor. Verantwortung für CRM-Daten und Analytik in den Bereichen Patientenakquise, Conversion und Bindung.

- CRM-Datenebene durchgängig neu aufgebaut und als Single Source of Truth für Vertrieb, Marketing und klinische Operations etabliert. Lead-Reaktionszeit -30 %, Conversion +15 %, Duplikate und Datenfehler -40 %, E-Mail-Engagement +25 %.
- Wöchentliches manuelles Tabellen-Reporting durch Echtzeit-Power-BI-Dashboards und Executive-Reports ersetzt; Reporting-Latenz von 7 Tagen auf live reduziert, ca. 6 Analystenstunden pro Woche bei der Berichtserstellung freigesetzt.
- CRM mit dem Marketing-Automation-Stack (E-Mail, SMS, Paid Funnels) integriert sowie Datenflüsse zwischen CRM, Patientenmanagementsystem und Marketing-Tools entwickelt, wodurch drei Tage manueller Abstimmung pro Woche entfielen.
- Unklare Stakeholder-Anfragen aus Marketing, klinischen Operations und Kundenservice in 12+ ausgelieferte Datenmodelle und Dashboards übersetzt, darunter die Lead-Scoring- und Conversion-Funnel-Modelle, die den 15 % Conversion-Uplift trieben.

Stack: SQL, Python, Power BI, Zoho CRM, Marketing-Automation, Workflow-Automation.

Strategic Data Insights Analyst · Federal Mortgage Bank of Nigeria · Abuja, Nigeria

12/2018 – 11/2019

Bundesweite Hypothekeninstitution für den nigerianischen Wohnungsbaufonds. Kreditportfolio-Analytik und IT-Governance-Reporting in der Asset Creation Unit der Loan-Administration-Gruppe.

- Zu einer Datenintegritätsinitiative beigetragen, die die Genauigkeit der Kerndatensätze in sechs Monaten um 40 % steigerte und das Risiko fehlerhafter Kreditgenehmigungen wesentlich reduzierte.
- Python- und SQL-Analytik auf Basis von Tableau gebaut, um Rückzahlungsverhalten zu verfolgen, und damit eine 15-prozentige Effizienzsteigerung im Rückzahlungs-Monitoring sowie eine 25-prozentige Reduktion des manuellen Dateneingabe-Aufwands unterstützt.
- Bearbeitungszeit der IT-Asset-Governance-Genehmigungen um 30 % reduziert durch Neukartierung des Approval-Workflows und Instrumentierung des Stage-Level-Reportings in Tableau, wodurch die Median-Zeit-bis-Genehmigung in der Loan-Administration-Gruppe geschrumpft ist.

Stack: Python, SQL, Tableau, Excel.

AUSBILDUNG

MSc Data Science · University of Salford · Manchester, Vereinigtes Königreich

01/2025 – 05/2026 · Note: Distinction (mit Auszeichnung) · Dissertation: Agentic ELT Data Platform for Customer Intelligence · Schwerpunkte: ML, Big-Data-Engineering, angewandte Statistik

MSc Big Data Analytics and Management · Bahçeşehir Üniversitesi · Istanbul, Türkei

09/2020 – 03/2023 · Note: 3,67 / 4,00 (ca. 1,7 nach deutschem System) · Masterarbeit: PySpark-Pipeline für Spielerempfehlungen in fünf europäischen Fußballligen (UEFA-Event-Daten)

BEng Computer Engineering · University of Benin · Edo, Nigeria

09/2011 – 08/2017

PROJEKTE

Agentic ELT Data Platform for Customer Intelligence

MSc-Dissertation (Salford) · 2026 · Live-B2B-SaaS-Umgebung

Eigenständiges Solo-Projekt von Anfang bis Ende: jede Schicht selbst entworfen und geschrieben, von der Ingestion bis zur Serving-API, gegen eine Live-B2B-SaaS-Umgebung unter NDA. Lief auf derselben Umgebung wie der Force24-Vertrag, ist aber unabhängige Eigenarbeit; die Force24-Plattform selbst war eine Teamlieferung.

- **Ingestion und Warehouse:** Eigene Python-Extraktoren ingestierten über 1 Mio. Datensätze aus mehreren Vendor-APIs in ein JSONB-orientiertes PostgreSQL-Warehouse, orchestriert mit Dagster.
- **Serving und Agent-Zugriff:** FastAPI-Service mit JWT-Auth und Row-Level-Security, Angular-Dashboard sowie Model-Context-Protocol-(MCP)-Endpoint, abfragbar durch jeden MCP-kompatiblen LLM-Agent für Per-Account-Risiko-Profiling, Treibererklärungen und Interventionsempfehlungen. Die Priorisierung der Ausgaben hob Hochrisiko-Accounts für CSM-Retention-Aktionen hervor.
- **Modellierung:** 48 dbt-Modelle über Raw-, Staging-, Intermediate- und Marts-Schichten; mehrschichtiges dimensionales Design nach Kimball.
- **Intelligence-Stack:** Survival-Analyse (kreuzvalidierter C-Index ca. 0,94 auf Held-Out-Kohorte) für Time-to-Churn; Gradient-Boosted-Klassifikation mit SHAP-Erklärungen (AUC ca. 0,95 gegenüber ca. 0,89 Logistic-Baseline) für Churn-Wahrscheinlichkeit und Treiber; DR-Learner-Causal-Inference (econml), die reaktive Zuweisungs-Selektionsbias um ca. 50 Prozentpunkte auf dem naiven Schätzer korrigiert, für eine ehrliche CSM-Treatment-Effect-Schätzung.

Python

PostgreSQL

JSONB

dbt

Dagster

PostgresML

XGBoost

SHAP

Causal Inference

Survival Analysis

FastAPI

Angular

MCP

Pharmaceutical Side Effect Classification

Eigenprojekt · 2025 · Healthcare-ML

Produktionsreifer Multi-Class-Klassifikator zur Zuordnung von Freitext-Beschreibungen unerwünschter Arzneimittelereignisse zu zehn klinischen Kategorien über 11.825 zugelassene Medikamente. Random Forest mit 98,5 % Genauigkeit auf der Test-Holdout-Menge, Logistic Regression als interpretierbarer Vergleich bei 97,2 %. Inference-CLI und pytest-Testsuite enthalten.

Python

scikit-learn

TF-IDF

Random Forest

Logistic Regression

Conflict Sentiment Analysis

Eigenprojekt · 2026 · NLP / Medienanalyse

Vergleichende Methodikstudie zur Frage, wie 8.158 englischsprachige Nachrichtenartikel den Russland-Ukraine-Konflikt über 68 Publisher in 18 Ländern framen. Drei Sentiment-Engines (RoBERTa, VADER, TextBlob) sowie ein gensim-LDA-Themenmodell auf demselben Korpus angewandt, um zu zeigen, wo die Wahl der Engine das Ergebnis verändert. Soloprojekt, durchgängig gebaut.

Python

RoBERTa

VADER

TextBlob

gensim LDA

NLP

Sentimentanalyse

Steam Games Recommender

Portfolio-Projekt · 2023 · Verteiltes ML

Collaborative-Filtering-Recommender auf dem Steam-200k-Implicit-Feedback-Datensatz. Verteiltes Alternating-Least-Squares-Training auf Spark MLlib mit Hyperparameter-Sweeps über CrossValidator und TrainValidationSplit, vollständiges Experiment-Tracking in MLflow, ausgeliefert auf Databricks Community Edition. End-to-End-ML-Lebenszyklus im verteilten Setting.

PySpark

Spark MLlib

ALS

MLflow

Databricks

Recommender Systems

TECHNISCHE KENNTNISSE

Sprachen: SQL, Python (pandas, NumPy, scikit-learn), R, PySpark, T-SQL, Bash

ML & Statistik: scikit-learn, XGBoost, PostgresML, scikit-survival, econml (DR-Learner), SHAP, MLflow, RoBERTa, ARIMA, NLP, Sentimentanalyse, TF-IDF, LDA, Causal Inference, Survival Analysis, A/B-Testing / Experimentation

Agentic AI: Model Context Protocol (MCP), agentische ELT, LLM-zugängliche Datenebenen

Service Layer: FastAPI, REST APIs, Docker, Caddy, Model Context Protocol (MCP)

Warehousing: PostgreSQL (JSONB + GIN), Snowflake, BigQuery, Databricks, SQL Server

Transformation & Orchestrierung: dbt, Dagster, Apache Spark, Airflow

Versionskontrolle & CI: Git, GitHub, GitHub Actions, pytest

Cloud: AWS, GCP, Azure, Oracle Cloud

BI & Visualisierung: Power BI, Tableau, Looker

SPRACHEN

- **Englisch:** Muttersprachlich
- **Deutsch:** B1

ZERTIFIKATE

- Engineer Data for Predictive Modeling with BigQuery ML · Google Cloud
- Python for Data Science, AI & Development · Coursera
- Generative AI for Business Leaders · Coursera
- Enterprise Design Thinking Practitioner / Team Essentials for AI / Co-Creator · IBM

ENGAGEMENT

Microsoft Learn Student Ambassador · Bahçeşehir Üniversitesi · Istanbul, Türkei

01/2021 – 09/2023 · Universitätsübergreifende Azure-Workshops und Community-Hackathon mit Ambassadors und Lernenden.

Verfügbarkeit: verfügbar ab Zusage zuzüglich Blue-Card-Verfahren (in der Regel 4–8 Wochen); Umzug nach Deutschland geplant.